

Разбор летучки

Лекция 11

Анализ смещения и разброса

Екатерина Тузова

Постановка задачи

X – множество объектов

Y – ответы в \mathbb{R}

Обучающая выборка: $X^l = (x_i, y_i)_{i=1}^l$

Целевая функция: $f : X \rightarrow Y$

Набор моделей алгоритмов $A_t : X \rightarrow Y, t \in T$

Методы обучения $\mu : (X \times Y)^l \rightarrow A_t, t \in T$

$$E_{in} = Q_{\mu}(X^l) = Q(\mu(X^l), X^l)$$

Внешний функционал по отложенной выборке:

$$E_{out} = Q_{\mu}(X^t, X^k) = Q(\mu(X^t), X^k)$$

$$E_{in} = Q(w, X^l) = \sum_{i=1}^l (f(x_i, w) - y_i)^2 = \|Xw - y\|^2 \rightarrow \min_w$$

Внешний функционал по отложенной выборке:

$$E_{out} = Q(w^*, X^k) = \|X^k w^* - y\|^2$$

Постановка задачи

Хотим: $E_{out} \rightarrow \min$

Хотим: $E_{out} \rightarrow \min$

$|A_t| \uparrow \Rightarrow$ больше шансов, что целевая функция f находится во множестве

$|A_t| \downarrow \Rightarrow$ лучше обобщающая способность алгоритма

Ошибка алгоритма складывается из двух частей:

- Насколько хорошо A_t может приблизить целевую функцию f
- Можем ли мы на основании X^l выбрать f из A_t

Квадратичная функция потерь:

$$L_i(a) = (a(x_i) - f(x_i))^2$$

Внутренний функционал:

$$E_{in} = \sum_{i=1}^l (a(x_i, w) - f(x_i))^2 \rightarrow \min_w$$

$$E_{out}(a^{(X^l)}) = \mathbb{E}_{\mathbf{x}} \left[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2 \right]$$

$$E_{out}(a^{(X^l)}) = \mathbb{E}_{\mathbf{x}} \left[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2 \right]$$

$$\begin{aligned} \mathbb{E}_{(X^l)} \left[E_{out}(a^{(X^l)}) \right] &= \mathbb{E}_{(X^l)} \left[\mathbb{E}_{\mathbf{x}} \left[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2 \right] \right] \\ &= \mathbb{E}_{\mathbf{x}} \left[\mathbb{E}_{(X^l)} \left[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2 \right] \right] \end{aligned}$$

$$\mathbb{E}_{(X^l)} \left[(a^{(X^l)}(\boldsymbol{x}) - f(\boldsymbol{x}))^2 \right]$$

$$\mathbb{E}_{(X^l)} \left[(a^{(X^l)}(x) - f(x))^2 \right]$$

$$\bar{a}(x) = \mathbb{E}_{(X^l)} \left[a^{(X^l)}(x) \right] \approx \frac{1}{K} \sum_{k=1}^K a^{X_k}(x)$$

X_1, \dots, X_K – различные обучающие выборки

$$\mathbb{E}_{(X^l)} \left[(a^{(X^l)}(\boldsymbol{x}) - f(\boldsymbol{x}))^2 \right] = \mathbb{E}_{(X^l)} \left[(a^{(X^l)}(\boldsymbol{x}) - \bar{a}(\boldsymbol{x}) + \bar{a}(\boldsymbol{x}) - f(\boldsymbol{x}))^2 \right]$$

$$\begin{aligned}\mathbb{E}_{(X^l)} \left[(a^{(X^l)}(x) - f(x))^2 \right] &= \mathbb{E}_{(X^l)} \left[(a^{(X^l)}(x) - \bar{a}(x) + \bar{a}(x) - f(x))^2 \right] \\ &= \mathbb{E}_{(X^l)} \left[(a^{(X^l)}(x) - \bar{a}(x))^2 + (\bar{a}(x) - f(x))^2 \right. \\ &\quad \left. + 2(a^{(X^l)}(x) - \bar{a}(x))(\bar{a}(x) - f(x)) \right]\end{aligned}$$

$$\begin{aligned}\mathbb{E}_{(X^l)} \left[(a^{(X^l)}(x) - f(x))^2 \right] &= \mathbb{E}_{(X^l)} \left[(a^{(X^l)}(x) - \bar{a}(x) + \bar{a}(x) - f(x))^2 \right] \\&= \mathbb{E}_{(X^l)} \left[(a^{(X^l)}(x) - \bar{a}(x))^2 + (\bar{a}(x) - f(x))^2 \right. \\&\quad \left. + 2(a^{(X^l)}(x) - \bar{a}(x))(\bar{a}(x) - f(x)) \right] \\&= \mathbb{E}_{(X^l)} \left[(a^{(X^l)}(x) - \bar{a}(x))^2 \right] + (\bar{a}(x) - f(x))^2\end{aligned}$$

$$\mathbb{E}_{(X^l)}[(a^{(X^l)}(x) - f(x))^2] = \underbrace{\mathbb{E}_{(X^l)}[(a^{(X^l)}(x) - \bar{a}(x))^2]}_{var(x)} + \underbrace{(\bar{a}(x) - f(x))^2}_{bias(x)}$$

$$\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2] = \underbrace{\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - \bar{a}(\mathbf{x}))^2]}_{var(\mathbf{x})} + \underbrace{(\bar{a}(\mathbf{x}) - f(\mathbf{x}))^2}_{bias(\mathbf{x})}$$

$$\mathbb{E}_{(X^l)}[E_{out}(a^{(X^l)})] = \mathbb{E}_{\mathbf{x}}[\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2]]$$

$$\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2] = \underbrace{\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - \bar{a}(\mathbf{x}))^2]}_{var(\mathbf{x})} + \underbrace{(\bar{a}(\mathbf{x}) - f(\mathbf{x}))^2}_{bias(\mathbf{x})}$$

$$\begin{aligned}\mathbb{E}_{(X^l)}[E_{out}(a^{(X^l)})] &= \mathbb{E}_{\mathbf{x}}[\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2]] \\ &= \mathbb{E}_{\mathbf{x}}[var(\mathbf{x}) + bias(\mathbf{x})]\end{aligned}$$

$$\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2] = \underbrace{\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - \bar{a}(\mathbf{x}))^2]}_{var(\mathbf{x})} + \underbrace{(\bar{a}(\mathbf{x}) - f(\mathbf{x}))^2}_{bias(\mathbf{x})}$$

$$\mathbb{E}_{(X^l)}[E_{out}(a^{(X^l)})] = \mathbb{E}_{\mathbf{x}}[\mathbb{E}_{(X^l)}[(a^{(X^l)}(\mathbf{x}) - f(\mathbf{x}))^2]]$$


$$= \mathbb{E}_{\mathbf{x}}[var(\mathbf{x}) + bias(\mathbf{x})]$$

$$= var + bias$$

Смещение (bias) – насколько сложное семейство моделей (средняя ошибка по всевозможным обучающим выборкам X^l)

Разброс (variance) – на сколько чувствителен алгоритм к изменению обучающей выборки (как отличается ошибка, если обучать модель на разных наборах данных)

Смещение и разброс



Как правило, при увеличении сложности модели увеличивается разброс оценки, но уменьшается смещение.

Как правило, при увеличении сложности модели увеличивается разброс оценки, но уменьшается смещение.

Если же модель слабая, то она не в состоянии выучить закономерность, в результате выучивается что-то другое, смещенное относительно правильного решения.


$$f(x) = \sin(\pi x)$$


Количество объектов $l = 2$

Рассмотрим 2 модели:

$$A_1 : h(x) = b$$


$$A_2 : h(x) = ax + b$$






A_1

Пример \sin




A_1




A_2

Обучение A_1, A_2




A_1

Обучение A_1, A_2




A_1





A_2


Bias-variance A_1





Bias-variance A_1




Bias-variance A_2



Bias-variance A_2




Bias-variance



bias = 0.50


var = 0.25

Bias-variance



bias = 0.50

var = 0.25



bias = 0.21

var = 1.69

Сложность модели нужно выбирать исходя из доступных данных, а не из предполагаемой сложности целевой функции.

Кривые обучения

$$\mathbb{E}_{(X^l)} \left[E_{out}(a^{(X^l)}) \right]$$

$$\mathbb{E}_{(X^l)} \left[E_{out}(a^{(X^l)}) \right]$$


$$\mathbb{E}_{(X^l)} \left[E_{in}(a^{(X^l)}) \right]$$

$$\mathbb{E}_{(X^l)} \left[E_{out}(a^{(X^l)}) \right]$$


$$\mathbb{E}_{(X^l)} \left[E_{in}(a^{(X^l)}) \right]$$

Как зависят от длины выборки?


Простая модель




High bias



Сложная модель



High variance



Вопросы?

Что почитать по этой лекции

- Professor Yaser Abu-Mostafa MOOC
- Hastie, T., Tibshirani R. "The Elements of Statistical Learning"
Chapter 7

На следующей лекции

- Методы восстановления регрессии
- K neighbors regressor
- Decision tree regression
- Neural Net Regression
- SVR